

第十届全国大学生生物医学工程创新设计竞赛
预赛作品报告模板

“颅镜”——颅内肿瘤影像临床诊断系统



作品 ID 号: 4570

参赛学生类型: (研究生)

参加赛道: (医工 AI 赋能赛)

组别: 自选项目组

2025 年 6 月

请勿在作品中出现参赛者及指导教师相关学校及个人信息，否则不予评审

内容完整性自查表

- 说明：
- 1. 命题组参赛作品请根据命题文件规定或要求的指标填写；
 - 2. 自选组参赛作品请根据实际参赛作品完成情况填写。

完整性类别	任务或技术指标名称	完成效果	呈现方式 (报告中的章节、页码，或者测试报告，或实物、视频等)
参赛作品任务或技术指标要求	1. 针对临床颅内肿瘤MRI影像自动化分类分级诊断，设计具有科学性和有效性的方案。	设计实现了基于多元解剖特征的双路径并行分层诊断网络，可通过颅内肿瘤的T1WI、T2WI、T1CE三个模态MRI影像自动识别肿瘤类型级别	2.1 作品实现的技术路线概述
	2. 针对不同级别和不同类型的颅内肿瘤特点，设计实现特征提取和肿瘤定位方案	设计基于渐进增强的多元解剖特征提取，精准提取三个模态影像颅内肿瘤边界和形态特征	2.2.2 基于渐进增强的多元解剖特征提取
	3. 设计颅内肿瘤影像自动分类分级模型	构建多元解剖特征的双路径并行分层诊断网络，双路径分别输入颅内影像的原始图像和特征图像，并行提取多模态特征，进行多特征融合，完成肿瘤分类分级任务。	2.2.3 模型结构设计
	4. 设计颅内肿瘤自动识别系统，节约临床资源	为模型设计GUI界面，加入多种功能，使用MATLAB的APPDesigner打包成可移植APP，设计用户友好界面，方便使用。	2.2.4 软件界面设计及实现过程
	5. APP的使用演示	对APP进行测试，录制演示视频，全方面展示APP	3.2 软件功能测试结果 大赛提交附件中的演示视频
其他			

摘 要

针对临床颅内肿瘤诊断需求迫切、传统方法效率低且易受主观影响的问题，本研究提出一种基于多元解剖特征的多模态 MRI 颅内肿瘤智能诊断系统。该系统提取颅内肿瘤 T1WI、T2WI、T1CE 序列 MRI 影像的多模态渐进增强特征，对肿瘤区域实现渐进转化，强化其解剖结构，深度挖掘肿瘤解剖特征。在此基础上，构建双路径并行分层诊断网络（MAF-DPNet），通过双路径实现多模态 MRI 图像与渐进增强特征图的跨模态融合学习，同步实现颅内肿瘤类型（弥漫性星形胶质瘤，少突胶质细胞瘤，少突星形胶质细胞瘤，间变性星形细胞瘤，间变性少突胶质细胞瘤，胶质母细胞瘤，弥漫性中线细胞瘤）与级别（II，III，IV 级）的高精度分类。依托辽宁省肿瘤医院临床数据进行验证，该系统在独立测试集上达到 97.8% 的肿瘤类型分类准确率与 98.0% 的肿瘤分级准确率，其中综合评价指标 F1-score 均大于 0.97。同时将模型进一步开发成为可移植桌面应用软件，集成图像上传、肿瘤定位、特征提取及诊断结果可视化功能，为临床医生提供高效辅助诊断工具，显著提升颅内肿瘤诊断的时效性与准确性。研究成果对提升颅内肿瘤诊断效率、减少误诊具有重要应用价值，未来可进一步探索多中心数据融合与实时诊断优化。

关键词：颅内肿瘤 MRI 图像，人工智能，肿瘤类型，肿瘤级别，自动诊断

目 录

摘要.....	I
1 作品概述.....	1
1.1 研究背景及意义.....	1
1.1.1 研究目的	1
1.1.2 研究背景	1
1.2 研究基础.....	2
1.2.1 研究现状和基本动态	2
1.2.2 项目实施基础条件	4
1.3 研究内容.....	4
1.4 研究目标.....	5
2 作品方案设计及实现.....	5
2.1 作品实现的技术路线概述.....	5
2.2 作品方案设计及实现过程.....	7
2.2.1 数据预处理	7
2.2.2 基于渐进增强的多元解剖特征提取	8
2.2.3 模型结构设计	9
2.2.4 软件界面设计及实现过程	12
3 作品测试方案及测试结果.....	13
3.1 模型指标及测试结果.....	13
3.1.1 肿瘤分类网络测试结果	14
3.1.2 肿瘤分级网络测试结果	16
3.2 软件功能测试结果.....	17
3.2.1 登录界面	17
3.2.2 图像显示	17
3.2.3 分类诊断结果显示	19
3.2.4 分级诊断结果显示	19

3.2.5 诊断意见显示	20
3.2.6 工具栏功能显示	20
3.3 创新说明	22
4 总结	22

1 作品概述

1.1 研究背景及意义

1.1.1 研究目的

根据柳叶刀子刊《神经病学》研究所示，在全球范围内，中国颅内肿瘤发病和死亡人数都排在第一位，因此对脑肿瘤进行精确识别、检测和治疗极其重要。颅内肿瘤包括原发性脑肿瘤和脑转移瘤，其最佳治疗手段是通过手术彻底切除。然而由于患者病情各不相同，且正常脑组织具有不可切除性，恶性肿瘤具有向颅内广泛浸润性生长的特点，采用手术的方法对肿瘤进行大范围彻底切除极为困难，需要根据患者具体情况确定治疗方案，因此掌握肿瘤的类型和严重程度信息对后续治疗方案的选定极其重要。在传统的临床诊断中，一般需要专业医生凭借丰富的医学知识，定性定量分析患者的病灶情况，才可对患者做出准确诊断。这种方式不仅依靠极大的人工作业，效率较低，还易由于医生的主观判断，降低肿瘤诊断的时效性与准确性。

因此，本项目聚焦于临床领域中颅内肿瘤诊断存在的问题，提出了基于多元解剖特征的颅内肿瘤诊断模型，秉持着“与时间赛跑，与死神较量”的肿瘤诊断理念，利用计算机辅助医疗技术，对患者脑部磁共振图像（MRI, magnetic resonance imaging）的肿瘤类型和肿瘤级别进行初步识别，以辅助医生更高效更准确的进行临床诊断，为后续患者治疗方案的确定提供了保障。

1.1.2 研究背景

在如今的临床环境中，由于颅内肿瘤患者的数量不断增多，其MRI影像数据量越发庞大。肿瘤诊断是一个十分严谨的过程，这使得医生需要花费更多的精力和时间去做出诊断。过多的工作量会使医生处于疲惫状态，进而影响其诊断的准确率，为后续的治疗埋下隐患。由于颅内肿瘤类型复杂多样，且具有相似的影像学特征，同种类型不同级别的肿瘤，其影像特征也可能区分不够明显，使得肉眼难以辨别，给医生的诊断工作增加了难度。

为解决这些问题，我们在所提模型的基础上设计了计算机辅助诊断系统，面对大量的影像学数据，该系统可在几秒钟之内输出肿瘤类型和级别的诊断结果，大大提高了肿瘤诊断的时效性，为临床诊断和后续治疗工作带来福音。同时该系统的诊断准确率较高，可有效减少误诊情况，尽量避免医患矛盾等一系列社会问题的发生。对于肿瘤类型和级别难以辨别的问题，我们采用基于多元解剖特征的颅内肿瘤诊断模型，通过计算机技术对大量的肿瘤细节特征进行学习，以训练模型的识别能力，辅助医生更好的进行临床诊断，一定程度上缓解了临床医疗资源紧张的局面。

1.2 研究基础

1.2.1 研究现状和基本动态

近年来，人工智能（artificial intelligence, AI）迅速发展并在许多领域广泛应用，尤其是在医学图像分析与生物信息学领域。许多医疗机构利用基于人工智能的算法来辅助诊断疾病并指导治疗，实现精准诊疗。对于肿瘤等复杂疾病现今已大多采用计算机辅助系统进行检测与诊断。而相对于其他肿瘤类疾病，颅内肿瘤对患者的生存质量和生存时间的影响尤其严重。如果能较早的发现并及时治疗，则可更好的保证患者的生存质量，并有效提升患者的五年存活率。

临床中，医学影像技术为脑肿瘤的早期诊断提供了支持，在众多成像方法中，MRI 技术为脑部软组织的多方位成像提供了较优的对比度，且具有无创、无辐射的特点，MRI 能获得原生三维断面成像而无需重建就可获得多方位的图像且软组织结构显示清晰，它的多序列成像为明确病变性质提供更丰富的影像信息。常用的 MRI 序列为 T1WI、T2WI、T1CE、DWI 等，影像学表现如图 1.1 所示。




图 1.1 不同序列 MRI 图像的影像学表现

在临床诊断中，医生需要阅读并分析大量的数据和影像等医学信息，计算机辅助诊断软件可以全面利用影像、数据等信息进行精确的定量计算和分析，避免因个人知识和经验的差异引起针对同一样本出现不同诊断结果，使得诊断变得更准确更易于操作。近年来，计算机辅助检测和诊断软件已经被开发出来帮助放射科医生诊断人体多个区的疾病，尤其在脑肿瘤方面的应用较为广泛，在诊断过程中，利用卷积神经网络(CNN, convolution neural network)深度学习方法来识别分类图像成为了主流趋势。基于 CNN 的方法是以数据驱动的方式，来构建复杂的神经网络模型，从而提取图像脑肿瘤特征，对图像进行识别分类。它克服了以往深度学习方法的局限性，其架构允许自身使用足够种类和质量的训练数据自动学习对问题重要的特征，最终能够获得高精确的结果。

肿瘤的分型、分级是目前评价肿瘤生物学行为和诊断的较为重要的两项指标。近数十年来，得益于生命科学和医学技术的突破性进展，通过对肿瘤类型的分类，可以使患者进行肿瘤个体化治疗。相关靶标的检测及包括靶向治疗在内的个体化

治疗药物的临床应用，不仅在很大程度上提高了早期肿瘤的检出率，也明显改善了许多肿瘤的预后。

对于颅内肿瘤类型分类，根据 2022 年出版的《脑胶质瘤诊疗指南》^[1]，颅内胶质瘤主要分为弥漫性星形胶质瘤、少突胶质细胞瘤、少突星形胶质细胞瘤、间变性星形细胞瘤、间变性少突胶质细胞瘤、胶质母细胞瘤、弥漫性中线胶质瘤这七类。弥漫性星形胶质细胞瘤 MRI 信号相对均匀，长 T1、长 T2 和 FLAIR 高信号，多无强化；少突胶质细胞瘤表现同弥漫性星形脑胶质瘤，常伴钙化；少突星形胶质细胞瘤融合了少突胶质瘤和星形胶质瘤特征，在 T2WI 中肿瘤周围可见轻至中度水肿带，多数伴有钙化；间变性星形细胞瘤的 MRI 序列中 T1WI 多呈低等混合信号，T2WI 上呈高等混合信号，T1WI 上常见中心高信号区周围绕以等信号环，环周可见高信号指样水肿征象；间变性少突胶质细胞瘤在 T1WI 中通常呈现出低信号，而在 T2WI 中则呈现高信号，病灶的中心常出现坏死；胶质母细胞瘤特征为不规则形周边强化和中央大量坏死，强化外可见水肿。弥漫中线胶质瘤常发生于丘脑、脑干等中线结构，MRI 表现为长 T1 长 T2 信号，增强扫描可有不同程度的强化。

对于颅内肿瘤的分级根据世界卫生组织标准将肿瘤分为 I、II、III、IV 级^[2]。I 级肿瘤的增殖潜力低，可通过手术切除治愈。癌细胞的恶性程度相对较低，不易复发和转移，MRI 信号相对表现均匀，为长 T1 信号、长 T2 信号，一般情况下无强化，部分肿瘤可能会伴有钙化现象。II 级肿瘤通常是浸润性的，尽管增殖活性较低，但经常复发。一些 II 级肿瘤倾向于发展为更高级别的恶性肿瘤，MRI 表现为肿瘤边界不清晰，周围具有轻度水肿，局部位置伴随轻度占位现象，中线几乎未发生偏移。III 级肿瘤通常为具有恶性组织学证据的病变，包括核异型性和活跃的有丝分裂活动。在大多数情况下，患者需要接受辅助放疗或化疗。III 级肿瘤多发于脑室内，MRI 表现为肿瘤边缘清晰，可能伴随有出血、囊变、坏死或钙化。IV 级肿瘤是指细胞恶性、有丝分裂活跃、易于坏死的肿瘤。具有广泛的周围组织浸润和颅内脊髓播散的特征。在 MRI 图像中，肿瘤常表现为周边不规则且肿瘤中央大部分坏死，受不同信号混杂的影响强化外部伴随水肿，部分病灶发生于丘脑、脑干等位置，各种信号可具有不同级别的强化。

不同类型的肿瘤以及同一种肿瘤的不同级别临床治疗方案会有所不同，因此，确定肿瘤病灶的位置、性质、体积、发展方向及对周围结构的浸润程度，对其做出确定性与鉴别诊断，对治疗患者及预后的制定尤为重要。

基于以上情况，我们将人工智能方法运用到临床检测中，在 CNN 的基础上，提出了基于多特征融合模型的脑肿瘤识别算法对颅内肿瘤进行特征提取与检测识别，实现了肿瘤类型和级别的精确识别，在一定程度上降低医生由于个体主观因素等对诊疗结果造成的误差，并为临床医生提供更为丰富和准确的医疗信息参考，为

患者提供更具针对性和有效性的治疗计划提供了保障，具有极大的应用价值和社会意义。

1.2.2 项目实施基础条件

在项目实施前期，从辽宁省肿瘤医院获取实际医学影像，通过与临床医生的线下线上交流，深入了解了影像科医生与临床医生的实际需求与现阶段脑部疾病诊断方面存在的医疗问题，并整理汇总医生与患者需求形成完整的需求文档，有针对性地研究解决目前神经外科尤其是脑部疾病相关医学问题的有效方法。通过查阅项目研究方向相关资料与文献，学习了目前深度学习方法的实现流程以及各种模型的优缺点，在项目实施过程中需要融合不同方法的优点，尽量保证项目效果最优化。项目已经经过医院患者本人允许，收集了大量颅内肿瘤相关MRI图像。

1.3 研究内容

及早的对患者进行诊断可极大的提高患者的存活率，具有重要意义。如何较为准确的对肿瘤进行识别也是目前临床中存在的重大挑战。本项目的研究内容如下所述：

（1）MRI 图像模态选择。研究表明，不同序列的 MRI 图像具有不同的肿瘤特征，会对分类结果产生不同的贡献值。对此，我们查阅资料对常见的 MRI 序列特点进行学习，结合数据集情况，最终选取 T1WI，T2WI，T1CE，最为实验数据，为模型提供肿瘤特征。

（2）特征提取：选择渐进增强的多元解剖特征提取方案，对图像的像素进行初始化及渐进转化，借助像素对应、建立缓冲、体素覆盖等操作，结合渐进增强策略，挖掘更具区分度的解剖特征。

（3）设计网络模型。设计了一种基于多元解剖特征的双路径并行分层诊断网络（Multi-Anatomical Features Dual-Path Diagnostic Network, MAF-DPNet）。该网络通过双路径分别提取原图与特征图信息，并对多模态信息进行多尺度特征融合，增强对病灶区域的识别能力。融合特征经深层卷积与全连接映射，最终输出肿瘤类型或分级结果，为后续诊断提供准确依据。

（4）模型进行训练。基于上述工作，对模型进行训练，根据训练结果进行技术优化和实验数据的补充。最后将训练好的模型参数保存到本地。

（5）设计颅内肿瘤自动识别系统。为了使本系统具有较高的应用价值，更好的辅助医生进行临床诊断，将本系统设计成独立的 APP，使其具备可移植性。本系统的开发平台为 MATLAB R2024A，借助 MATLAB 和 JAVA 的混合编程，将已保存的模型参数导入到本系统 APP 中。为了便于医生的使用，在 APP 的开发过程中

对用户界面进行设计，设计功能按钮区、结果展示区和辅助菜单按钮，界面清晰，易于使用，具有良好的交互性。且为了使医生在诊断过程中更好的观察肿瘤病灶，本系统还设计了肿瘤定位功能和肿瘤区域特征提取功能，提高了本系统的应用价值。

1.4 研究目标

(1)病灶区域定位，基于颅内肿瘤 MRI 影像中病灶的边界，纹理，形态特征，实现对颅内肿瘤所在位置的精准定位，清晰呈现肿瘤在颅内的具体位置及与周围组织的空间关系。

(2) 颅内影像类型分类，设计网络模型对颅内肿瘤 MRI 影像进行类型分类，明确区分弥漫性星形胶质瘤、少突胶质细胞瘤等七种类型的颅内肿瘤。

(3)颅内影像患病程度分级，设计网络模型，学习肿瘤不同病程阶段的特征，对颅内肿瘤 MRI 影像进行患病程度分级，判断肿瘤的恶性程度。

(4) 实现颅内肿瘤影像的自动化识别，节约医疗资源，加快诊断效率，为患者争取更多的治疗时间。

2 作品方案设计及实现

2.1 作品实现的技术路线概述

本研究聚焦颅内肿瘤诊断难题，以辽宁省肿瘤医院为数据支撑，基于多模态颅内肿瘤 MRI 影像的 T1WI、T1CE、T2WI 序列，开展肿瘤类型与级别精准诊断研究。首先，通过渐进增强的多元解剖特征提取方案，对影像的像素进行初始化及渐进转化，借助像素对应、建立缓冲、像素覆盖等操作，结合渐进增强策略，挖掘更具区分度的解剖特征，为后续诊断奠定基础。

在此基础上，构建“双轨并行+特征融合”的诊断模型体系，以 MRI 模态选择、数据增强的预处理为前置环节，完成两个诊断分类任务：一是肿瘤类型七分类，搭建颅内肿瘤类型诊断模型，经数据平衡处理后，构建双路径结构融入多模态 MRI 影像与多元解剖特征，实施多尺度特征融合与跨模态特征融合，实现肿瘤类型精准判别。二是肿瘤级别三分类任务，构建颅内肿瘤级别诊断模型，依托多模态协作机制，开展多尺度、跨模态特征融合，完成肿瘤 II 级、III 级、IV 级的精细分级。

最终，构建临床多模态颅内肿瘤数据验证集，从肿瘤类型诊断结果、级别诊断结果两维度，对模型进行实证分析验证，为颅内肿瘤临床精准诊断、治疗方案制定提供关键依据，总体技术路线如图 2.1 所示。




图 2.1 拟采取的总体研究方案

2.2 作品方案设计及实现过程

2.2.1 数据预处理

(1) MRI 模态选择

MRI 通过不同成像序列，能够从多维度呈现人体组织的微观结构和生理特征，生成多种模态图像，为疾病诊断提供丰富信息。一般常规 MRI 扫描序列为 T2WI、T1WI、T1CE、FLAIR 和 DWI。

T1WI 主要反映组织间纵向弛豫时间 T1 值的差异。其成像特点是，短 T1 值组织呈现高信号，如脂肪，在图像中表现为白色或亮灰色；长 T1 值组织则显示为低信号，如脑脊液，呈黑色或暗灰色。T1WI 对解剖结构的显示极为清晰，能够精准呈现组织的形态、大小和位置关系，尤其适用于观察脑部灰白质结构、区分正常与病变组织的解剖边界。

T2WI 侧重于体现组织横向弛豫时间 T2 值的不同。长 T2 值组织在图像中表现为高信号，如脑脊液、水肿组织，显示为亮白色；短 T2 值组织则呈现低信号，如骨皮质、钙化灶，呈黑色。T2WI 对病变组织的敏感性较高，能够清晰显示病变区域的范围、水肿程度以及组织内的含水量变化，在检测炎症、肿瘤、脱髓鞘病变等方面具有显著优势。

FLAIR 可以抑制脑脊液的高信号，能够更清晰地显示靠近脑脊液区域的病变，如脑室旁的脑梗死、脑部炎症等。对于检测和评估中枢神经系统疾病具有重要意义，能够提高微小病变的检出率。

DWI 为弥散加权成像基于水分子的弥散运动成像，反映组织内水分子的运动状态。在急性脑梗死早期，由于细胞毒性水肿导致水分子弥散受限，病变区域在 DWI 图像上表现为高信号，有助于早期诊断脑缺血性病变。

T1CE 序列是在做 MRI 之前往血液注射造影剂，亮的地方血供丰富，强化显示说明血流丰富，而肿瘤部位正是血流很快的部位，T1CE 序列还能进一步显示肿瘤内情况，鉴别肿瘤与非肿瘤性病变。

通过查阅脑肿瘤相关论文资料，结合从医院收集整理的临床数据，本项目选择 T1WI、T2WI 和 T1CE 作为实验数据。T1WI 拥有优异的解剖结构显示能力，能够清晰界定肿瘤的边界和位置，可以帮助网络快速判断肿瘤与周围正常组织的关系。T2WI 对病变组织的高敏感性使其能够清晰呈现肿瘤的形态、大小以及周围水肿情况，对于发现肿瘤病变、评估肿瘤的浸润范围具有关键作用。T1CE 通过注射对比剂，能够突出显示肿瘤组织的血供情况，因为肿瘤组织通常具有丰富的血管和较高的血管通透性，在增强图像上会表现出明显的强化，这有助于区分肿瘤的良恶性，评估肿瘤的活性，同时还能检测出一些在平扫图像中难以发现的微小病灶。

(2) 数据增强

本作品实验数据均为辽宁省肿瘤医院提供的实际临床数据,共包含 75 个被试,部分被试含有多个时间检查的 MRI 图像。数据集内的图像均含有两类标签,分别是肿瘤类型和肿瘤级别标签,标签为临床医生根据图像所诊断标注,数据格式为 DCM 文件。筛选出 T1WI、T2WI、T1CE 三个序列后,发现两类数据集中的数据均存在类别间数量不平衡的现象,这种数据不平衡会影响模型的学习效果,因此选择对数据进行数据增强处理,数据规模如表 3.1 和表 3.2 所示。

表 3.1 增强后的肿瘤类别标签数据集

标签	弥漫性星 形胶质瘤	少突胶质 细胞瘤	少突星形胶 质细胞瘤	间变性星 形细胞瘤	间变性少突 胶质细胞瘤	胶质母 细胞瘤	弥漫性中线 细胞瘤
被试数量	3	8	6	11	9	37	1
图片数量	420	324	348	1170	714	906	141

表 3.2 增强后的肿瘤级别标签数据集

标签	II 级	III 级	IV 级
被试数量	17	14	44
图片数量	1092	1014	1917

2.2.2 基于渐进增强的多元解剖特征提取

由于部分 MRI 图像中肿瘤所在区域并不明显,为了获得肿瘤的内部细节,我们通过渐进式增强图像的方法,强化图像的解剖特征作为先验知识,并进一步扩大了数据集。同时,后续的双路输入网络融合了颅内肿瘤 T1WI、T2WI 和 T1CE 序列及其多元解剖特征,实现了对颅内肿瘤临床数据集的有效分类分级。

分类分级的关键在于识别颅内肿瘤区域并判断不同级别之间的病理差异。渐进图像能够更好地突出病变及其内部细节,并增强 T1WI、T2WI 和 T1CE 中局部模糊的区域。所提出的特征提取方法是根据像素对应关系将原始 T1WI、T2WI 和 T1CE 图像 X_2 转换为相应的渐进增强图像 X_p ,该增强图像突出了病变及其清晰的边界,并反映了肿瘤的侵袭程度和严重性。

从 X_2 到 X_p 的转换过程如下:首先需要为 X_2 的每个像素 $X_{2i}(x, y)$ 创建对应的缓冲区 $\xi_i(x, y)$ 。然后,每个缓冲区 $\xi_i(x, y)$ 会被填充从内到外的灰度像素。此外,通过叠加和覆盖像素值来迭代交叉缓冲区。对于胶质瘤区域,交叉缓冲区的重叠越多,像素值越大,表明肿瘤的侵袭程度越高。最后,根据与灰度级对应的彩虹色阶,重新分配像素值并进行着色,从而获得渐进增强图像 X_{pi} 。每个级别和类型的图像特征提取后的结果分别如图 2.2 和图 2.3 所示。




图 2.2 不同级别颅内肿瘤的渐进增强解剖特征提取




图 2.3 不同类别颅内肿瘤的渐进增强解剖特征提取

2.2.3 模型结构设计

为有效融合多模态影像信息与其对应的渐进增强特征，本文设计了一种基于多元解剖特征的双路径并行分层诊断网络（Multi-Anatomical Features Dual-Path Diagnostic Network, MAF-DPNet）。该网络旨在充分提取原始 MRI 图像与其解剖特征的多层次特征信息，从而提升肿瘤识别与分级的准确率。其整体结构如图 2.4 所示。

MAF-DPNet 采用双路径输入结构，其中一个路径的输入为 MRI 的 T1WI、T1CE、T2WI 多模态序列的原图，有效捕捉肿瘤及周围组织的形态学结构特征，如边缘形状、大小、纹理等信息。另一个路径的输入为与原图对应的 T1WI、T1CE、T2WI 解剖特征图，特征图由前文提到的图像渐进增强方法获得，有助于对病灶区域的形态学与解剖特征进行提取。这种双路径结构可以更好地提取多模态图像的上下文敏感信息^[1]，其中使用了卷积层（Conv）、跨通道归一化层（Norm）、池化层（Pool），卷积层中使用了 11×11 、 5×5 、 3×3 的卷积核使得卷积层能够很好地捕捉肿瘤的局部解剖特征和内部细节。同时，在卷积层之后加入跨通道归一化层，帮助校正和优化解剖特征，降低各层的依赖性，减少内部变量偏移，加快网络训练速度。将卷积后的结果输入到池化层，进行最大池化操作，更好地保留肿瘤特征中的最强响应，如病灶区域的边缘、信号增强区和形态异常区，同时加强了网络对异常区域的敏感性，有助于后续的融合操作。

双路径提取后的原图特征与解剖特征在 Add 层进行逐元素融合，实现跨模态信息的高层级整合。这种融合方式保留了两种输入各自的判别能力，同时增强了模型对关键区域的关注。

跨模态特征融合后，进行深度特征提取，以进一步提升模型的判别能力。融合特征经过连续的三个卷积层，每层卷积核可以学习更大感受野范围内的特征组合，每个卷积层后面都接着一个 ReLU 激活函数，增强模型表达能力并避免梯度消失。随后，特征通过三层全连接结构进行高维映射，最终通过 Softmax 层输出各类别的概率分布。网络结构和参数如表 3.3 所示。

本项目提出的模型完成两个任务，肿瘤类型七分类与肿瘤级别三分类。在肿瘤分类的任务中，网络最终输出为肿瘤图像所对应七个类别的概率结果，如图 2.4 中 Task1 所示。在肿瘤分级的任务中，网络最终输出为肿瘤图像所对应三个级别的概率结果，如图 2.4 中 Task2 所示。

表 3.3 MAF-DPNet 网络结构参数表

名称	类型	激活	可学习参数大小
Input	图像输入	$227 \times 227 \times 3$	--
Conv1/Conv1'	二维卷积	$55 \times 55 \times 96$	Weights $11 \times 11 \times 3 \times 96$

			Bias 1×1×96
ReLU1/ReLU1'	ReLU	55×55×96	--
Norm1/Norm1'	跨通道归一化	55×55×96	--
Pool/Pool1'	最大池化	27×27×96	--
			Weights 5×5×48×128×2
Conv2/Conv2'	二维分组卷积	27×27×256	Bias 1×1×128×2
ReLU2/ReLU2'	ReLU	27×27×256	--
Norm2/Norm2'	跨通道归一化	27×27×256	--
Pool2/Pool2'	最大池化	13×13×256	--
Add	加法	13×13×256	--
			Weights 3×3×256×384
Conv3	二维卷积	13×13×384	Bias 1×1×384
ReLU3	ReLU	13×13×384	--
			Weights 3×3×192×192×2
Conv4	二维分组卷积	13×13×384	Bias 1×1×192×2
ReLU4	ReLU	13×13×384	--
			Weights 3×3×192×128×2
Conv5	二维分组卷积	13×13×256	Bias 1×1×128×2
ReLU5	ReLU	13×13×256	--
			Weights 4096×43264
FC1	全连接	4096×1	Bias 4096×1
ReLU6	ReLU	4096×1	--
			Weights 64×4096
FC2	全连接	64×1	Bias 64×1
ReLU7	ReLU	64×1	--
			Weights 7×4096
FC3	全连接	7×1	Bias 7×1
Softmax	Softmax	7×1	--
Output	分类输出	7×1	--




图 2.4 MAF-DPNet 模型结构图

2.2.4 软件界面设计及实现过程

为了更好地辅助医生使用本产品来诊断颅内肿瘤的类型和严重程度，我们将系统设计成可移植独立安装使用的 APP 形式，满足医生在电脑没有 MATLAB 的情况下，也可以使用本产品进行颅内肿瘤分类。本产品使用了多种控件、算法以及不同功能连接，实现上传图像、肿瘤患病区域定位、肿瘤特征提取、肿瘤类型诊断、肿瘤级别诊断、显示个人信息、显示结果、参考疾病描述诊断、清空界面等功能，进行了合理布局，并设计了 APP 的帮助说明，方便医生使用。图 2.5 为基于 MATLAB APP Designer 开发的软件 GUI 界面。以下进行详细阐述：

（1）上传图像模块：用户点击“上传图像”按钮，程序会弹出文件选择对话框，支持用户选择单个图像样本的 JPG 或 PNG 格式的图像，上传后的图像显示在中间的 UIAxes 框架内，患者的姓名、年龄、性别的信息对应显示在右边的文本框中。

（2）肿瘤定位功能：点击“肿瘤定位”按钮，对肿瘤的区域进行分割，首先将原始图像转换为二值图像，随后使用圆盘形结构元素进行形态学腐蚀和膨胀操作，以估计图像的背景结构。通过图像减法运算，分离出与背景显著不同的区域，并应用连通区域分析移除小面积噪声。最后，再次通过图像减法和区域过滤，提取出目标特征。肿瘤位置分割图片显示在中间区域的图像定位标签下。

（3）特征提取功能：将前文提到的肿瘤图像特征提取算法代码，移植到 GUI

“特征提取”按钮的回调函数中，实现特征提取，对应的图片显示在中间区域的特征面板标签下。

（4）肿瘤类型：在网络训练结束后，使用 `save` 函数将训练好的肿瘤七分类网络保存为 `mat` 格式的文件，设计 GUI 界面时，将 `mat` 文件导入到“肿瘤类型”回调函数中，即可以使用训练好的网络来对图像进行预测，可以大大减少了重复训练的时间。使用时点击“肿瘤类型”按钮，右侧的“肿瘤类型”的文本框中显示网络判断的肿瘤类型结果。

（5）肿瘤级别：原理与“肿瘤类型”按钮相同，保存训练结束后的肿瘤级别三分类网络为 `mat` 文件，导入文件到对应按钮的回调函数中，使用时点击“肿瘤级别”按钮，右侧的“肿瘤类型”的文本框中显示网络判断的肿瘤级别结果。

（6）诊断意见：读取患者就诊时的医生给出的肿瘤描述和诊断意见，将结果显示在右侧“参考肿瘤描述与诊断意见”的文本框里面。可以作为金标准检验网络判断结果的正确性。



图 2.5 APP 的 GUI 界面设计

3 作品测试方案及测试结果

3.1 模型指标及测试结果

本项目的实验预处理和特征提取网络训练部分在 `Matlab R2024a` 平台上完成

的。

将数据集以 8: 2 来随机划分为训练集和测试集, 训练网络过程中, 采用 `sgdm` 优化器, 其有助于加速收敛, 减少原有随机梯度下降的震荡问题, 每次迭代使用的数据量 `MiniBatchSize` 设置为 64, 学习率设置为 0.0001, 选择最大迭代次数 `MaxEpochs` 为 30。训练集用来训练模型学习各类图像的病变特征, 测试集用来测试模型的分类效果。

为了验证所提出的模型对胶质瘤分类和分级的性能, 使用混淆矩阵来展示实验结果, 通过准确率 (`accuracy`)^[4]、精确率 (`precision`)^[5]、特异性 (`specificity`)^[6]、召回率 (`recall`)^[7]、`F1-score`^[8] 这些评价指标来对实验结果进行有效的评估。各评价指标计算公式如下所示:

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

$$precision = \frac{TP}{TP + FP} \quad (2)$$

$$recall = \frac{TP}{TP + FN} \quad (3)$$

$$specificity = \frac{TN}{TN + FP} \quad (4)$$

$$F1-score = \frac{2 * precision * recall}{precision + recall} \quad (5)$$

式中, `TP` 和 `TN` 分别为准确分类的阳性和阴性样本。`FP` 和 `FN` 分别表示未准确分类的阳性和阴性样本。以上性能指标的范围为[0,1], 数值越大, 表示模型分类效果越好。为公平起见, 计算各类别指标值的宏观平均值作为最终评价结果^[9]。

3.1.1 肿瘤分类网络测试结果

在训练过程中, 随着迭代次数的增加, 训练准确率和损失如图 3.1 所示。从图 3.1 可以看出, 训练准确率经过前期的上升和波动后是稳定的, 而损失相对较小, 平滑后趋于稳定。测试过程中, 本文提出模型的混淆矩阵结果如图 3.2 所示, 其中 1 表示“弥漫性星形胶质瘤”, 2 表示“少突胶质细胞瘤”, 3 表示“少突星形胶质细胞瘤”, 4 表示“间变性星形细胞瘤”, 5 表示“间变性少突胶质细胞瘤”, 6 表示“胶质母细胞瘤”, 7 表示“弥漫性中线细胞瘤”。从表中可以看出, 测试集的准确率为 97.8%。七个类别的评价指标宏平均值, 如表 3.1 所示。




图 3.1 肿瘤分类模型训练过程图




图 3.2 肿瘤分类模型测试结果图

表 3.1 肿瘤分类的测试集评价指标

评价指标	<i>accuracy</i>	<i>precision</i>	<i>specificity</i>	<i>recall</i>	<i>F1-score</i>
平均值	0.9785	0.9820	0.9961	0.9762	0.9791

3.1.2 肿瘤分级网络测试结果

训练过程中曲线如图 3.3 所示，从图中可以看出在训练后期的分类准确率稳定为 100%。损失率趋近 0，证明了模型的学习效果优异。对于胶质瘤 MRI 图像的分级，测试集的结果如图 3.4 的混淆矩阵所示，测试准确率达到 0.98，本文方法通过获取和综合胶质瘤的病理特征，并进行多特征融合，可以识别不同级别的胶质瘤。当前的偏差可能是由于相似隐藏特征的识别错误造成的。评价指标如表 3.2 所示，所有指标均达到 0.97 以上，证明分类的效果稳定。




图 3.3 肿瘤分级任务的训练曲线图




图 3.4 肿瘤分级任务的混淆矩阵

表 3.2 肿瘤分级任务的评价指标

评价指标	<i>accuracy</i>	<i>precision</i>	<i>specificity</i>	<i>recall</i>	<i>F1-score</i>
平均值	0.9801	0.9788	0.9898	0.9793	0.9789

3.2 软件功能测试结果

3.2.1 登录界面

设计的 APP 具有登录界面,医生可以填入自己的账号和密码,登录使用 APP,初始密码为 Victory, 密码为“6666”, 界面如图 3.5 所示。



图 3.5 登录界面

3.2.2 图像显示

点击上传图像后,原图显示在中间区域的 MRI 面板下,对应的患者信息显示在右侧文本框内,如图 3.6 所示。




图 3.6 原图显示

点击肿瘤定位按钮,中间区域面板跳转到肿瘤定位的标签下,肿瘤分割定位后

的图像显示在面板下，如图 3.7 所示。




图 3.7 肿瘤定位效果图

点击特征提取按钮，中间区域面板跳转到特征面板的标签下，特征提取后的图像显示在面板下，如图 3.8 所示。




图 3.8 肿瘤特征提取

3. 2. 3 分类诊断结果显示

点击肿瘤类型按钮，对应的肿瘤类型显示在右侧文本框内，如图 3.9 所示。




图 3.9 肿瘤分类诊断结果显示

3.2.4 分级诊断结果显示

点击肿瘤级别按钮，对应的肿瘤级别显示在右侧文本框内，如图 3.10 所示。




图 3.10 肿瘤分级诊断结果显示

3.2.5 诊断意见显示

点击诊断意见按钮，对应的参考肿瘤描述集诊断意见显示在右侧文本框内，肿瘤真实的类型和级别出现在文本框中，与模型判断的一致，证明模型测试结果准确，如图 3.11 所示。




图 3.11 肿瘤诊断意见结果显示

3.2.6 工具栏功能显示

工具栏中包含文件、帮助、联系我们、退出四个按钮。

点击文件按钮，出现一个保存的下拉按钮，点击保存，可以对整个界面图像进行截图，用户根据自己的需求，自定义文件名字，保存到自定义位置。如图 3.12 所示




图 3.12 保存按钮功能

点击帮助按钮，出现一个“帮助指引”信息框，用来说明介绍的功能和使用方法，帮助用户使用系统如图 3.13 所示。



图 3.13 帮助按钮功能

点击帮助按钮，出现联系开发者的信息框。如图 3.14 所示。




图 3.14 联系开发者功能

点击退出按钮，退出系统，如图 3.15 所示。




图 3.15 退出功能

3.3 创新说明

本项目有以下创新点：

- 1、采用多模态融合策略，将序列 MRI 图像输入网络模型，为模型提供更具价值的肿瘤特征，有利于后续模型进行多特征融合提取。
- 2、双路径并行分层诊断模型，两条路径分别处理原始图像信息和特征图信息，从结构设计上有效提升了模型对细节的学习能力与分类性能。
- 3、采用临床数据集，同时实现颅内肿瘤类型和肿瘤级别的自动化识别，辅助医生进行高效诊断，节省临床资源，有较高的临床应用价值。
- 4、设计的 APP 为独立的桌面应用程序，具有较好的移植性。

4 总结

本项目成功构建了融合渐进特征提取与双路径网络的多模态 MRI 颅内肿瘤诊断系统，通过创新性地结合像素级特征增强与跨模态融合机制，实现了对 7 类肿瘤类型和 3 级恶性程度 MRI 影像的同步精准识别，测试准确率均超过 0.978。所开发的独立软件具备肿瘤定位、特征可视化及诊断结果输出功能，经临床验证有效提升了诊断效率。

尽管系统取得显著成效，未来工作可从以下方向深化：（1）进行数据规模扩展，当前数据集样本量有限，后续可以联合多中心医疗数据扩充样本多样性，进一步提

升罕见类型诊断鲁棒性。(2)进行多模态深度整合,后续可以探索融合 DWI、FLAIR 等序列影像,构建更全面的肿瘤生物学特征图谱。

参考文献

- [1] 国家卫生健康委员会医政医管局,中国抗癌协会脑胶质瘤专业委员会,中国医师协会脑胶质瘤专业委员会.脑胶质瘤诊疗指南(2022 版)[J].中华神经外科杂志,2022,38(8):757-777.DOI:10.3760/cma.j.cn112050-20220510-00239.
- [2] 苏昌亮,李丽,陈小伟,等.2016 年 WHO 中枢神经系统肿瘤分类总结[J].放射学实践,2016,31(07):570-579.DOI:10.13609/j.cnki.1000-0313.2016.07.001.
- [3] Fang, Lingling, and Yumeng Jiang. "Dual-path parallel hierarchical diagnostic model of glioma based on pathomorphological feature." Biomedical Signal Processing and Control 87 (2024): 105559.
- [4] S. Saxena, et al., Brain tumour segmentation in FLAIR MRI using sliding window texture feature extraction followed by Fuzzy C-means clustering, Int. J. Healthc. Inform. Syst. Inform. 16 (3) (2021) 1–20.
- [5] T. Maruyama, et al., Simultaneous brain structure segmentation in magnetic resonance images using deep convolutional neural networks, Radiol. Phys. Technol. 14 (2021) 358–365.
- [6] S.P. Gayathri, S.R. Siva, K. Somasundaram, Fetal brain segmentation using improved maximum entropy threshold, Int. J. Innov. Technol. Explor. Eng. 9 (3) (2020) 1805–1812.
- [7] Q. Yang, H. Zhang, J. Xia, X. Zhang, Evaluation of magnetic resonance image segmentation in brain low-grade gliomas using support vector machine and convolutional neural network, Quant. Imaging Med. Surg. 11 (1) (2021) 300–316.
- [8] A.A. Asiri, et al., A novel hybrid machine learning approach for classification of brain tumor images, Comput., Mater. Continua 73 (1) (2022) 641–655.
- [9] Y. Gao et al., Histological grade and type classification of glioma using Magnetic Resonance Imaging, in: International Congress on Image and Signal Processing, BioMedical Engineering and Informatics, pp. 1808-1813, 2016. 10.1109/CISPBMEI.2016.7853011.